

# Reporte de lectura: *Automatic Speech Recognition: A survey of deep learning techniques and approaches*

León-Altamirano F. Z. C.

21 de enero de 2026

## Introducción y Contexto

El **Reconocimiento Automático del Habla (ASR)**, por sus siglas en inglés<sup>1</sup> es el proceso tecnológico en el cual se reconoce y traduce automáticamente el lenguaje hablado a texto. Las primeras estrategias utilizadas para lograr este reconocimiento hacían uso de una extracción manual de características, así como técnicas estándar como Modelos de Mezclas Gaussianas (GMM), Máquinas de Soporte Vectorial (SVM) y los Modelos Ocultos de Markov (HMM). Sin embargo, estos primeros intentos presentaban limitaciones importantes al intentar resolver problemas complejos a gran escala en la realidad.

Desde 2010, los métodos de redes neuronales profundas (DNN) han revolucionado el campo del ASR, desplazando así a los modelos utilizados inicialmente. El proceso del ASR moderno se resume en las siguientes cuatro etapas: **Preprocesamiento** para limpiar el audio, **Extracción de Características** para obtener coeficientes acústicos, **Clasificación** mediante modelos de aprendizaje profundo, y la **aplicación de un Modelo de Lenguaje (LM)** para corregir errores gramaticales y semánticos.

## (Breve) Historia de los métodos utilizados

La evolución del ASR ha sido marcada por saltos significativos en la capacidad de procesamiento y cantidad de datos de entrenamiento. El lanzamiento de Google Voice Search en 2010 marcó un punto de inflexión, pues con ella millones de personas pudieron utilizar ASR, mientras que Google logró adquirir miles de millones de consultas para mejorar sus predicciones. Entre 2011 y 2012, investigaciones demostraron que sustituir los modelos GMM por Redes Neuronales Profundas (DNN) reducía de forma significativa el error de reconocimiento.

Posteriormente, las Redes Neuronales Recurrentes (RNN), específicamente las de tipo bidireccional (BiRNN) y con memoria de corto y largo plazo (LSTM), permitieron capturar dependencias temporales y contextos futuros en el habla. En 2014, Deep Search, un modelo que se entrenó directamente con espectrogramas de voz para generar transcripciones de texto tuvo gran impacto, pues no requirió de tratamiento del ruido, reverberación o variaciones del hablante para mejorar la precisión del modelo.

A partir de 2017, la arquitectura **Transformer** permitió reemplazar por completo las recurrencias y convoluciones, basándose exclusivamente en mecanismos de auto-atención para construir dependencias globales. El modelo Conformer, presentado en 2020, modificó este enfoque al integrar convoluciones para capturar características locales y Transformers para el contexto global, lo que permitió utilizar menos parámetros para realizar el entrenamiento.

Los últimos avances se resumen en adaptaciones de diferentes técnicas y enfoques, sumados a un aumento considerable en la cantidad de datos utilizados y parámetros a entrenar, que han ido desde 34 millones en 2019, hasta 2.3 miles de millones en 2023.

---

<sup>1</sup>En lo sucesivo se hará uso de estas siglas para abreviar.

## Datasets y Métricas de Evaluación

Para el entrenamiento de estos modelos se han desarrollado diversos datasets. Entre los que están sólo en inglés, destaco **LibriSpeech**, un dataset **Open Source**, que contiene aproximadamente 1,000 horas de habla segmentada de audiolibros. En cuanto al ámbito multilingüe, destaco Common Voice, un proyecto de Mozilla en el cual los usuarios pueden colaborar añadiendo grabaciones o verificando que una grabación corresponda correctamente al texto, y que a la fecha de realización del artículo contaba con más de 18 mil horas validadas.

La precisión se mide principalmente mediante el Word Error Rate (WER), que calcula la tasa de error a nivel de palabra usando la distancia de Levenshtein. Otras métricas incluyen el Character Error Rate (CER) para caracteres y el Phone Error Rate (PER) para fonemas.

## Reflexión

Leer el artículo me ha permitido reconsiderar como el ASR ha pasado de tener pocas aplicaciones iniciales a una gran cantidad en la actualidad; por ejemplo, pasó de ser una funcionalidad *extra* de Google Search a ser utilizada en otras aplicaciones, como dispositivos similares a Alexa, servicios de ventas y/o atención a clientes que funcionan por agentes, entre otros.

Coincido con el autor en que existen varias **dificultades sociales por abordar**, entre las cuales las siguientes me parecen más importantes:

- **Idiomas con pocos datos de entrenamiento:** Existe una diferencia significativa en la precisión entre lenguajes, mientras que en inglés el WER puede ser de 1.4, en idiomas como el hindi el error es notablemente más alto debido a falta de datos de entrenamiento.
- **Variabilidad de los acentos:** El desempeño de un sistema ASR puede verse disminuido al ser entrenado con datos en los cuales un acento o dialecto esté subrepresentado.
- **Sesgo:** Los modelos pueden terminar aprendiendo sesgos presentes en los datos de entrenamiento, por ejemplo, si en un conjunto de datos los mismos pertenecen principalmente a una población de características similares.

El autor también menciona ciertas consideraciones respecto del **alto coste computacional** que tiene no solo entrenar sino poner en producción modelos de ASR. En la actualidad el coste de entrenamiento no solo de ASR, sino de prácticamente de todo modelo de Inteligencia artificial ha llevado a un aumento de precio desmesurado en componentes como GPU, RAM y de almacenamiento. Esperaría que, en unos 10 años hubiese algún otro hito que permitiera un aumento en la precisión sin requerir de tantos recursos; o bien, se logren mejorar los componentes físicos lo suficiente para soportar el alto coste computacional de los algoritmos de DL actuales.

Finalmente, creo que las iniciativas **Open Source** (como los de Mozilla) adquieren especial relevancia en mitigar los retos sociales, pues permiten recabar datos de una población mayor. Para que dichas iniciativas resulten efectivas, las mismas deberían de tener una mayor publicidad, e incluso algún tipo de estímulo que incentiven la participación de hablantes de lenguas marginadas<sup>2</sup>.

---

<sup>2</sup>Por supuesto, habría que analizarse la factibilidad de esto.